附件 4

华夏银行数字科技创新孵化项目技术方案
（前沿技术研究类）

1 目标与考核指标

1.1 课题目标

围绕申报指南提出项目（课题）目标，目标要完整、明确。

课题 1：自动化数据测评

课题 2：构建稳健的大模型评价体系：挑战与解决方案

课题 n:

1.2 考核指标

围绕申报指南提出项目（课题）考核指标，指标应系统、完整、客观。

量化指标应说明指标数据的具体含义、数据范围和数据获取方式。

课题 1

课题 2

课题 3

2 主要研发内容、关键技术及创新点、风险分析

2.1 主要研发内容

大型语言模型（LLM），如 GPT-4、PaLM 2 和 LLaMA，在文本分类、问答系统等 NLP 任务中表现优异，并能快速生成高质量训练数据，显著降低时间和人力成本。尽管如此，这些生成的数据可能存在噪声和偏差，影响模型微调效果。因此，引入自动化筛选工具成为关键，它能够提高数据处理效率，减少主观偏差，确保数据质量，为模型微调提供可靠支持。

然而，要全面优化大模型的性能，仅依精调数据筛选还不够，还需要构建一个系统化的评价指标体系。随着大模型规模和复杂性的增加，传统指标已无法全面反映其在不同任务和应用场景中的表现。科学的评价体系不仅能更准确地评估模型的优劣，还能通过数据驱动的分析帮助开发者优化模型结构和功能。不同应用场景对大模型的需求各异，评价体系有助于选择和开发最合适的模型，提高实际应用中的有效性，避免资源浪费。此外，该体系还关注透明度、可解释性和公平性等问题，确保模型在实际应用中的合规性和可靠性，避免伦理问题和社会风险。建立这样的评价体系，不仅推动现有模型的优化，还为未来的模型研究提供统一标准，促进人工智能领域的持续创新与发展，为企业决策者在大模型选择和应用中提供科学依据，降低决策风险，推动技术的健康发展。

2.2 关键技术及创新点

课题的首个创新点在于将检索增强模式应用于自动化数据评估。具体来说，由于语言模型无法像人类一样理解自我认知的边界，也无法意识到自身输出是否存在问题，因此无法质疑提示中的前提，甚至可能重复之前犯过的错误，这些问题是导致生成的精调数据出现偏差的关键原因之一。为解决大模型的认知边界问题，检索增强文本生成成为一种有效方法。该方法通过检索真实文档作为外部知识来源，帮助大模型生成更加可靠且具备可解释性的文本，不仅扩展了大模型的知识范围，还显著提高了生成内容的准确性和可信度。此外，检索增强技术在微调数据的自动化筛选中也展现了巨大潜力。系统可以通过检索相关文档来验证大模型生成的数据是否与外部事实或标准一致，从而判定数据的可用性，减少对人工筛选的依赖，提高筛选效率，避免主观偏差。这种检索增强筛选技术能够自动检测并过滤掉存在偏差或错误的数据，确保用于微调的数据具备更高质量和准确性，为大规模数据处理和模型优化提供了一条可行且高效的路径，有助于推动大模型在复杂任务中的应用和发展。

该课题的另一个创新点在于构建一个科学而全面的大模型评价指标体系，通过精细化的指标框架、评测方法、评测数据集和量化评估，确保大模型在不同应用场景中的性能得到准确、全面的评估。指标框架明确了关键的评估维度和标准，指导开发者在模型优化过程中聚焦于最重要的能力提升。评测方法则通过自动化测试、用户反馈和人工评估等手段，具体执行评价任务，确保评估的客观性和有效性。选取适合的评测数据集也是关键，数据集不仅要代表模型在实际应用中的任务场景，还要符合框架设定的标准。最终，量化评估能够提供模型性能的客观数据，为开发者设计和优化模型提供科学依据。通过这些环环相扣的部分，该评价体系不仅能指导大模型的持续改进，还能帮助开发者为特定应用场景设计出最合适的模型，从而推动大模型技术的进一步发展和应用。

2.3 风险分析

自动化测评大模型生成的数据存在多重风险，包括难以识别和纠正模型吸收的偏见、误报与漏报导致的错误评估、以及在处理复杂或多义内容时对语境和意图的理解不足。此外，数据隐私和安全问题也可能导致敏感信息泄露，而在伦理问题识别上的不足可能使有害内容被误判为可接受。过度依赖自动化测评可能忽视人工审查的必要性，因此需要在系统设计中结合人工与自动化评估，并重视透明性、公平性和安全性，以有效减轻这些风险。

其次，在构建大模型评价体系时，主要风险包括**系统的复杂性与资源需求以及评测数据集的质量与适用性**。评价体系涉及多个相互依赖的组件，如指标框架、评测方法、数据集准备和评测指标设定，这些复杂关系需要大量计算资源、时间和专业知识，不当的资源管理可能导致评估效率和结果准确性下降。为降低这些风险，可通过模块化设计、明确分工和合理分配资源来优化评估过程，同时利用自动化工具提高效率。另一个关键风险是数据集的质量与适用性，低质量或不适用的数据集会导致评估结果的偏差或失真，影响模型优化方向。为确保数据集有效性，需构建严格的数据筛选标准，选择经过验证的数据集，并注意隐私保护、法律法规遵守及伦理问题，以避免潜在的法律和道德风险。

3 技术方案、技术路线及计划进度

3.1 自动化数据评估

如图所示，利用检索文档进行判定大模型生成内容是否合适的技术路线可以分为以下几个步骤。这个过程结合了文本生成、信息检索和自动化判断技术，主要分为三部分，分别为大模型生成内容、信息检索与相似性分析。

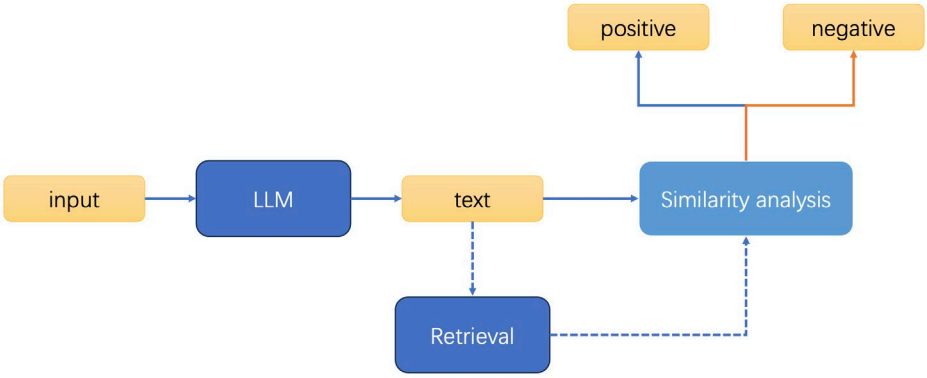

图 1：自动化测评路线图

LLM 内容生成

为了使大模型生成格式正确的精调数据，首先需要构建易于大模型理解的 prompt。其次，利用构建的 prompt 输入至 LLM，初步得到 LLM 生成的微调数据：

$$T_{gen} = LLM(prompt)$$

其次，为了提高检索和分析的准确性。通过分句、分段和去噪，可以将生成文本分成更小的、更适应于项目需求的的可用数据，并进一步确保后续的检索和相似度分析更准确有效：

$$T_{proc} = Preprocess(T_{gen})$$

信息检索

由于生成的微调数据集是特定于任务的，因此在利用检索去判断生成内容是否可靠时，首先需要设定一个包含N篇相关领域文档的文档库$D = \{d_1, d_2, \dots, d_n\}$，其中每个文档$d$都包含$c_i$份内容。

其次，采用信息检索模型，如 BM25 或 BERT-based 检索模型，进行文档检索。对于每篇文档d_j，计算其文档句子c_{ji}的相关性得分：

$$source_{ji} = R(Q, c_{ji})$$

其中j表示文档编号，i表示文档中句子编号

根据相关性得分$source_{ji}$，对文档进行降序排序，选择前m个相关性最高的文档作为候选文档集D_{top}：

$$D_{top} = (c_{j1}, \dots, c_{nm})$$

其中$source_{j1} > \cdots > source_{nm}$

自动化判断和评分

接下来，使用语义相似模型$S(T_{proc}, c_{ji})$（如 BERT）计算生成内容T_{proc}和候选文档集D_{top}中各文档的语义相似度Sim_{ji}：

$$Sim_{ji} = S(T_{proc}, c_{ji})$$

之后，需要再检查生成内容与候选文档中事实的匹配情况，这是为了进一步检查生成内容内部逻辑的一致性，尤其是在涉及多个相关信息时，确保不存在逻辑矛盾。在这，我们使用一致性分析函数$F(T_{proc}, c_{ji})$计算一致性得分：

$$Consist_{ji} = F(T_{proc}, c_{ji})$$

综合相似性得分Sim_{ji}和一致性得分$Consist_{ji}$，计算生成内容的综合评分$Score_{total}$：

$$Score_{total} = \alpha \times \frac{1}{m}\sum_{i=1}^{m} Sim_i + \beta \times \frac{1}{m}\sum_{i=1}^{m} Sim_i$$

其中α和β是权重系数，用于平衡语义相似度和一致性在总评分中的影响。

最后，设定适用性阈值λ，若$Score_{total} > \lambda$，则判定生成内容为适用,否则，标记为需进一步审核或不适用。

3.2 大模型评价体系

大模型评价体系被分为四个关键部分：指标框架、评测方法、评测数据集和评测指标，这是为了确保评估过程的系统性、全面性和精确性。每个部分在整个评价体系中都有其特定的功能和重要性。

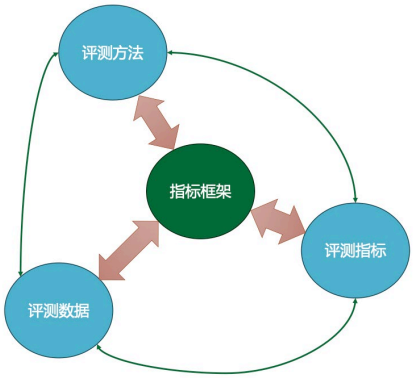

图 2：体系结构图

如图 2 ，我们可以清晰地看到大模型评价指标体系中的四个关键部分及其相互关系。核心的指标框架位于图的中心，象征着它作为整个评价过程的基础和指导原则。在指标框架的指导下，评测方法、评测数据集和评测指标这三个重要元素围绕其展开，分别承担具体的评测任务、数据支持和性能量化的职责。

图中的箭头展示了指标框架对这三大元素的指导作用，同时这三者之间的相互连接形成了一个闭环，表明它们之间的紧密关联和相互依存。评测方法依赖于选定的评测数据集来执行，而评测指标则通过对这些方法的结果进行量化来反映模型的性能。这种结构展示了一个完整且连续的评价流程，确保模型的每一个关键方面都能得到准确的评估与优化。

指标框架

指标框架是评价体系的核心，因为它定义了评价的目标和关键维度。通过设定明确的框架，可以确保评估过程有一个清晰的方向和标准，避免评估中的随意性和不一致性。不同任务需要不同的评价指标，为了准确衡量模型的表现，评价指标必须与任务的具体需求相匹配。这是因为每个任务的目标、数据特性、复杂性和应用场景各不相同。例如，图像分类任务侧重于准确率，而自然语言处理任务可能需要考虑生成内容的准确性和流畅性。因此，针对不同任务定制评价指标，能够全面反映模型的有效性和适用性。

- 幻觉(Hallucinations)：检测幻觉是确保大模型生成内容可靠性和准确性的关键。首先，准确的信息对于用户决策至关重要，尤其是在涉及医疗建议、法律事务或新闻报道时。其次，避免误导和虚假信息能够保护用户免受错误信息的影响，并维护公众对模型的信任。最后，符合伦理和法律规范是应用模型的基本要求，确保生成内容不违反相关法规或伦理标准。通过使用专门设计的幻觉检测数据集，并结合准确率、F1 分数等指标，可以有效评估大模型是否存在幻觉问题。
- 准确性(Accuracy):准确性是模型的基础属性，输出的准确性决定了模型是否可用。在评测中，准确性是每个评测场景和任务中准确性度量的总称，包括文本分类中的精确匹配(EM)，问题回答中基于词重叠的 F1 分数，信息检索的 MRR，计算生成文本中事实准确性 FEQA 以及 BLEU 等指标等。
- 鲁棒性(Robustness):鲁棒性指的是模型在面对输入的扰动时能够保持其性能的能力。例如，一个鲁棒的模型应该能够在问题被稍微改写或包含轻微的打字错误的情况下，仍然能够正确地回答问题。鲁棒性对于实际应用特别重要，因为输入往往是嘈杂的或具有敌意的。在语言模型的背景下，可以通过扰动输入文本并测量模型输出的变化来评估鲁棒性，评价鲁棒性的主要指标 Adversarial Accuracy 等。

- 效率(Efficiency):效率通常指的是模型的计算效率,包括训练和推理的时间、算力资源。效率会影响模型在实际应用中的可行性。例如，一个非常准确的模型如果需要大量的计算资源或者时间来进行训练或推理，那么它可能就不适合在资源有限或者需要快速响应的环境中使用。目前，主要使用的指标包括推理时间、参数数量等。
- 安全性（Safety)：模型与用户的交互对话应该是健康无毒的，符合一定的安全和道德规范，并且模型应该拥有一定的抵抗对抗攻击或越狱攻击的能力。模型可能会在回应中包含仇恨、有害或危险的评论，并在人类用户询问时产生危险内容。这些输出不仅降低了用户的信任，而且对遵守安全法规构成了挑战。评测安全性的指标包括毒性检测等。
- 隐私性（Privacy)：一般的机器学习模型容易受到数据隐私攻击，即攻击者或恶意用户使用特殊技术从模型或系统中提取隐私信息。模型的输出应该不涉及训练过程中的隐私数据，具有良好隐私性的模型应该能够避免通过恶意提示来提取训练数据的敏感数据。评测指标一般包括：差分隐私等。

评测方法

基础模型和微调模型需要采用不同的评测方式，因为它们的训练目标和应用场景不同。基础模型通常是为了具备广泛的泛化能力，适用于多种任务，因此评测时侧重于其在多任务、多领域的表现。而微调模型经过专门优化，适用于特定任务或领域，因此评测应聚焦于其在目标任务中的表现、精度和实用性。

针对基础模型和微调模型采用不同的测评方式。

基础模型评测以“适配评测+提示学习评测”的**客观评测**为主。

1、**任务类型**：主要针对那些可以自动评测且有标准答案的任务，如分类、选择题问答和信息检索。这些任务的标准答案可以由系统自动验证。。

2、**评测方式**：通常采用 In-context 形式进行评测，支持 Few-Shot 和 Zero-Shot,即在不需要额外训练的情况下,通过少量示例或无示例的方式进行测试。

3、**基础设施**：保持统一的算力和数据基础设施，以确保评测的一致性和公平性。

4、**数据量和速度**：使用大规模的数据进行评测，速度快，适合快速验证模型性能。然而，这种方法通常只能评测有限的能力维度。

5、**工具和数据来源**：利用丰富的 benchmark（基准测试集）和自动化评测工具，如数据采样和指标计算，来提高评测的效率和准确性。

微调模型评测先复用基础模型的客观评测，考察微调过程是否对基础模型造成了某些能力的提升或下降。然后再引入**主观评测**。

1、**任务类型**：主要针对无法自动评测且没有标准答案的任务，如开放问答、条件文本生成等。

2、**评测方式**：通常采用对话的形式进行评测，以 Zero-Shot 为主，即无需额外训练示例。

3、**标注过程**：通过多轮评测标准培训和多人背靠背标注，使用标注工具辅助，确保标注的质量和一致性。

4、**数据量和速度**：评测数据量相对较小，评测速度较慢，但能够覆盖丰富的能力维度，并且有助于发现模型的弱点。

5、**标注团队**：依赖经验丰富的评测标注团队，保证评测的专业性和准确性。

评测数据集

通过“任务”、“能力”解耦，每个任务应对多样化的能力，并通过多样化的数据集来评定。

任务	主任务	数据集
问答	单跳问答	Natural Question(NQ)，TriviaQA(TQA)，SQuAD，Web Questions(WebQ)，PopQA，MS MSRCO
	多跳问答	HotpotQA，2WikiMultiHopQA，MuSiQue
	长格式问答	ELI5，NarrativeQA(NQA)，ASQA，QMSum
	领域问答	Qasper，COVID-QA，CMB，MMCU_Medical
	多项选择问答	QuALITY，ARC，CommonsenseQA
	图问答	GraphQA
对话	对话生成	Wizard of Wikipedia (WoW)
	个人对话	KBP，DuleMon
	任务导向对话	CamRest
	推荐	Amazon(Toys,Sport,Beauty)
事件提取	事件参数提取	WikiEvent，RAMS
	关系提取	T-REx，ZsRE
推理	常识推理	HellaSwag
	思维链推理	CoT Reasoning
	复杂推理	CSQA
幻觉检测	问答	HalluQA
	文本生成	Hades
其他	语言理解	MMLU
	语言建模	WikiText-103，StrategyQA
	事实核查	FEVER，PubHealth
	文本生成	Biography
	文本摘要	WikiASP，XSum
	文本分类	VioLens，TREC

情感	SST-2
代码搜索	CodeSearchNet
鲁棒性评估	NoMIRACL
数学	GSM8K
机器翻译	JRC-Acquis
毒性检测	TOXICSPANS

评测指标

1、EM（Exact Match）

（1）简介

EM（Exact Match）是一种用于评估问答系统性能的指标，特别是在自然语言处理任务中，例如阅读理解和问答系统。EM 衡量的是生成的答案是否与参考答案完全匹配，即两者是否完全一致。它是一个二元指标，通常用于评估系统在给定问题下提供的答案是否准确无误。

（2）计算方式

EM 的计算过程包括以下几个步骤，公式如下：

生成答案和参考答案：

对于每个查询q_i，系统生成一个答案A_i，并且参考答案为R_i。

比较答案：

比较生成答案A_i和参考答案R_i是否完全一致。如果A_i与R_i完全相同，则匹配；否则不匹配。

计算准确率：

对于每个查询，判断生成答案是否与参考答案完全一致：

$$Match = \begin{cases} 1, & if\ A_i = R_i \\ 0, & if\ A_i \neq R_i \end{cases}$$

计算 EM 分数：

计算所有查询的准确率的平均值，得到 Mean Exact Match（EM）分数：

$$EM = \frac{1}{N}\sum_{i=1}^{N} Match_i$$

其中N是查询的总数量，$Match_i$是第i个查询的匹配结果。

2、**基于词重叠的 F1 分数**

（1）简介

基于词重叠的 F1 分数是一种用于评估文本生成和问答系统性能的指标。它结合了精确率（Precision）和召回率（Recall），用于衡量生成文本与参考文本之间的重叠程度。F1 分数能够综合考虑正确答案的覆盖范围和生成答案的准确性，广泛应用于机器翻译、文本摘要和问答系统中。

（2）计算方式

F1 分数的计算过程包括以下几个步骤，公式如下：

提取匹配的词汇：

从生成的答案和参考答案中提取出匹配的词汇集合。设生成的答案为Gen，参考答案为 Ref。匹配的词汇集合为：

$$Match = Gen \cap Ref$$

计算精确率（Precision）：

精确率是匹配词汇与生成答案中总词汇的比例。公式为：

$$Precision = \frac{|Match|}{|Gen|}$$

其中$|Match|$是匹配词汇的数量，$|Gen|$是生成答案中的词汇总数。

计算召回率（Recall）：

召回率是匹配词汇与参考答案中总词汇的比例。公式为：

$$Recall = \frac{|Match|}{|Ref|}$$

其中$|Ref|$是参考答案中的词汇总数。

计算 F1 分数：

F1 分数是精确率和召回率的调和平均值，计算公式为：

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

3、信息检索中的 MRR（Mean Reciprocal Rank）

（1）简介

MRR（Mean Reciprocal Rank）是一种用于评估信息检索系统性能的指标，特别适用于查询结果的排名。它衡量的是在一组查询中，相关文档出现的平均位置，反映了系统在返回相关文档方面的有效性。MRR 通常用于评估搜索引擎、问答系统和推荐系统的检索能力。

（2）计算方式

MRR 的计算过程包括以下几个步骤，公式如下：

确定相关文档的位置：

对于每个查询q_i，计算相关文档在检索结果中的位置。设第i个查询的相关文档位置为r_i（位置从 1 开始计数）。如果没有相关文档，则r_i被视为无限大。

计算每个查询的倒数排名：

对于每个查询q_i，计算倒数排名（Reciprocal Rank，RR）：

$$RR_i = \frac{1}{r_i}$$

其中r_i是i个查询中第一个相关文档的位置。

计算 MRR：

计算所有查询的倒数排名的平均值，得到 Mean Reciprocal Rank：

$$MRR = \frac{1}{N}\sum_{i=1}^{N} RR_i$$

其中N是查询的总数量，RR_i是第i个查询的倒数排名。

4、困惑度（Perplexity）

（1）简介

困惑度（Perplexity）是衡量语言模型性能的重要指标，常用于评估语言模型对文本的预测能力。它量化了语言模型在生成或预测下一个词时的“困惑”程度，困惑度越低，表示模型对文本的预测越准确。困惑度广泛应用于自然语言处理任务，如语言建模、机器翻译和文本生成。

（2）计算方式

困惑度的计算过程包括以下几个步骤，公式如下：

生成答案和参考答案：

给定一个词序列$w_1, w_2, \dots, w_N$，首先计算模型对每个词w_i的条件概率$P(w_i|w_1, w_2, \dots, w_{i-1})$。这些概率反映了模型对每个词出现的预测能力。

计算词序列的似然度：

计算整个词序列的似然度，即所有词的条件概率的连乘积：

$$P(w_1, w_2, \dots, w_N) = \prod_{i=1}^{N} P(w_i|w_1, w_2, \dots, w_{i-1})$$

计算交叉熵（Cross-Entropy）：

交叉熵是对词序列似然度的对数取负：

$$H = -\frac{1}{N}\sum_{i=1}^{N} logP(w_i|w_1, w_2, \dots, w_{i-1})$$

计算困惑度：

困惑度是交叉熵的指数函数，公式为：

$$Perplexity = exp\,(H)$$

其中H是交叉熵，表示模型对词序列的平均困惑度。

5、FEQA

（1）简介

FEQA（Fact-based Question Answering）指标是用于评估生成文本中事实准确性的一种方法，尤其常用于生成式自然语言处理（NLP）任务，如摘要生成、对话生成等。在这些任务中，生成的文本是否准确表达了源文本中的事实是一个重要的评估指标。

（2）计算方式

FEQA 的计算过程包括以下几个步骤，公式如下：

提取答案：

首先，给定源段落的摘要$text$，FEQA 会屏蔽重要的标记a，这些标记由成分解析器和 NER（命名实体识别）模型自动提取：

$$a, text_q = NER(text)$$

其中a表示屏蔽的标记（即答案），$text_q$屏蔽答案之后的文本，NER表示命名实体识别模型。

生成问题：

然后，使用学习模型生成与屏蔽标记相对应的问题q_g，并将屏蔽标记视为其黄金答案a：

$$q_g = model(text_q)$$

其中q_g表示生成的问题。

回答问题：

QA 模型根据源段落回答生成的问题：

$$a_g = QAmodel(q_g, text)$$

其中a_g表示根据生成问题得到的答案。

计算 FEQA 得分：

最后，计算生成答案与实际答案的$FEQA_{Score}$：

$$FEQA_{Score} = F1(a, a_g)$$

6、BLUE

（1）简介

BLEU（Bilingual Evaluation Understudy）是一种常用于机器翻译质量评估的指标，也可用于其他自然语言处理任务，如文本摘要等。BLEU 通过比较系统生成的翻译结果与参考翻译之间的相似度来评估翻译的质量。

在 LLM（Large Language Models）中，特别是在 RAG（Retrieval-Augmented Generation）领域，BLEU 指标用于评估生成式模型生成的文本与人类编写的参考文本之间的相似性和质量。在 RAG 模型中，生成式模型会生成一段文本作为回答，BLEU 指标可以帮助评估这些生成文本的质量和相关性。

（2）计算方式

$$BLEU = BP \times \exp\left(\sum_{n=1}^{N} \omega_n \cdot logP_n\right)$$

其中，BP 是惩罚因子，用于惩罚过度翻译长度的影响，通常称为 Brevity Penalty，它的计算方式是

$$BP = \begin{cases} 1, \text{如果} c > r \\ exp(1 - \frac{r}{c}), \text{如果} c \leq r \end{cases}$$

其中，c 是系统生成的翻译结果的长度，r 是参考翻译的长度；N 是考虑的 n-gram 的最大长度；ω_n是每个 n-gram 的权重，通常为$\frac{1}{N}$。P_n是 n-gram 的精确匹配率（Precision），即系统生成的翻译中与参考翻译相匹配的 n-gram 的数量除以系统生成的翻译中的总 n-gram 数量。

7、推理时间（Inference Time）

（1）简介

推理时间指的是模型在给定输入下，生成预测结果所需的时间。较短的推理时间通常意味着模型更高效，适合实时应用。

（2）计算方式

对于每个输入样本，记录从输入到输出生成的时间，并计算平均值：

$$Average\ Inference\ Time = \frac{1}{N}\sum_{i=1}^{N} t_i$$

其中N是测试样本数量，t_i是单个样本推理时间。

8、Adversarial Accuracy

（1）简介

Adversarial Accuracy 是一种用于评估模型在对抗性攻击（adversarial attacks）下表现的指标。对抗性攻击是指通过对输入数据进行微小但有针对性的扰动，试图欺骗模型做出错误预测。Adversarial Accuracy 衡量的是模型在这些扰动下仍然能够正确分类或预测的比例。该指标通常用于评估深度学习模型的鲁棒性（robustness），尤其是在图像分类、自然语言处理等领域。

（2）计算方式

Adversarial Accuracy 的计算过程包括以下几个步骤，公式如下：

生成对抗样本：

对于给定的输入数据x，生成对应的对抗样本x^1，使得x^1是在原始数据x上施加了微小扰动后的结果。对抗样本x^1的目标是使模型对其预测结果错误。

预测对抗样本：

使用模型对生成的对抗样本x^1进行预测，得到预测结果y^1。

比较预测结果与真实标签：

对每个对抗样本，比较模型的预测结果y^1与原始数据的真实标签y是否一致。如果一致，则认为模型在该对抗样本上成功抵抗了攻击。

计算 Adversarial Accuracy：

计算所有对抗样本中模型预测正确的比例，公式为：

$$\text{Adversarial Accuracy} = \frac{1}{N}\sum_{i=1}^{N} 1(y^{1i} = y^i)$$

其中N是对抗样本的总数量，y^{1i}是第i对抗样本的预测结果，y^i是第i个样本的真实标签，$1(y^{1i} = y^i)$表示如果预测正确则为 1，反之为 0。

9、毒性检测（Toxicity Detection）

（1）简介

毒性检测（Toxicity Detection）是大模型安全性评价中的一个关键指标，用于评估模型生成有害或冒犯性内容的风险。随着大规模语言模型在对话生成、文本生成等任务中的广泛应用，确保它们不会输出有毒性内容变得尤为重要。

（2）计算方式

毒性检测通常通过以下几种方法来实现：

标注数据集：

使利用标注过的毒性内容数据集（如 TOXICSPANS 数据集）来训练和评估模型。这些数据集包含了已知的有毒和无毒文本，并可以用于监督模型的训练。。

分类模型：

训练分类模型来识别文本中的毒性内容。该模型可以基于多种特征，如词汇特征、上下文语义等，对输入文本进行分类：

$$p = \frac{1}{1 + e^{-z}}$$

其中，z是模型输出的线性组合，包含了输入特征（如词向量、句向量）和模型参数（权重与偏置）

毒性评分：

模型对每个生成的文本段落进行评分，给出一个毒性概率值p。通常，设定一个阈值，超过该阈值θ的文本被认为是有毒的。

$$label = \begin{cases} 1\text{，如果}p > \theta \\ 0\text{，如果}c \leq \theta \end{cases}$$

9、差分隐私

（1）简介

差分隐私是一种隐私保护技术，通过在数据分析过程中引入可控的噪声来平衡数据可用性和个体隐私之间的关系。差分隐私通过在数据集中引入随机性，使得针对不同个体的查询结果之间的差异变得模糊和不可靠。这些随机性操作在保护隐私的同时，仍允许从数据集中提取有用的统计信息。

（2）计算方式

差分隐私如何保护个人数据：

差分隐私定义：

差分隐私保证在进行数据分析时，任何单个数据点的添加或删除对最终输出的影响都非常小。具体而言，给定两个相邻数据集D和D^1（它们只在一个数据点上不同），差分隐私机制M应满足：

$$p_r[M(D) = O] \leq e^{\varepsilon} p_r[M(D^1) = O]$$

其中ε是隐私预算（privacy budget），控制隐私级别。值越小，隐私保护越强，O是输出结 果，p_r表示概率

该定义表明，数据集发生微笑变化时，分析结果都不会有显著变化，从而有效地保护了个体隐私。

差分隐私数据保护：

在发布或共享数据集之前，对数据进行处理，使得任何对数据集的查询都满足差分隐私要求：

1、**添加噪声**：对统计数据或直接对数据集添加噪声。

2、**数据预处理**：去除可能直接识别个人的标识信息。例如，删除或加密个人身份证号码、姓名等直接关联到个人身份的信息。

3、**数据合成**：生成一个合成数据集，既保留数据的统计性质，又保护个体数据的隐私。

4. 预期成果形式与知识产权归属

预期成果形式如专利、论文、专著等，并列明知识产权归属。

5 其他

需要约定的其它内容